



BURSA TEKNİK ÜNİVERSİTESİ

Veri Madenciliğine Giriş

Karar Ağacı ile Obezite Seviyesi Tahmini

Efekan Aksoy - 22360859031

İçindekiler

Giriş	2
Veri Seti	2
Veri Ön İşleme	3
Yöntem: Karar Ağacı	4
GUI Kullanımı	8
Literatür Karşılaştırması	9
Sonuç	9
Bağlantılar	10
Kaynakça	10

Giriş

Günümüzde obezite en büyük küresel sağlık krizlerinden biri haline gelmiştir. Dünya Sağlık Örgütü'nün güncel raporlarına göre dünya genelinde 1 milyardan fazla kişi obezite ile savaşılmaktadır. Bu değer küresel nüfusun neredeyse 8'de 1'ine denk gelmektedir. Obezitenin doğru ölçümü ve erken tespiti, obezitenin yol açabileceği kalp damar hastalıkları veya belirli kanser türleri gibi birçok kronik hastalığının çözümünde kritik rol oynamaktadır.

Bireylere ait sağlık kayıtlarının ve yaşam tarzı verilerinin devasa boyutlara ulaşması geleneksel istatistik yöntemleri ile analizi çok zor bir hale getirmiştir. Bu noktada makine öğrenmesi algoritmaları sağlık alanında da gerekli hale gelmiştir. Bu çalışmada Karar Ağacı algoritması kullanılarak bireylerin beslenme alışkanlıkları ve yaşam tercihleri verisinden obezite seviyesinin tahmin edilmesi amaçlanmıştır.

Veri Seti

Meksika, Peru ve Kolombiya'dan toplanan veriler 2111 satır, 17 özellik ve 1 hedef değişken içermektedir. Veri setinin %77'si sentetik olarak SMOTE yöntemiyle üretilmiştir.

Özellik	Tip	Açıklama
Gender	İkili	Cinsiyet
Age	Sürekli	Yaş
Height	Sürekli	Boy (cm)
Weight	Sürekli	Kilo (kg)
family_history_with_overweight	İkili	Ailede obezite öyküsü
FAVC	İkili	Yüksek kalorili gıda tüketimi
FCVC	Sürekli	Sebze tüketim sıklığı (1-3)
NCP	Sürekli	Günlük öğün sayısı
CAEC	Ordinal	Öğün arası atıştırma sıklığı
SMOKE	İkili	Sigara kullanımı
CH2O	Sürekli	Günlük su tüketimi (litre)
SCC	İkili	Kalori takibi
FAF	Sürekli	Fiziksel aktivite sıklığı(0-3)
TUE	Sürekli	Teknoloji kullanım süresi (saat)
CALC	Ordinal	Alkol tüketim sıklığı
MTRANS	Nominal	Ulaşım Aracı

Hedef deęiřken 7 sınıflı obezite etiketi içermektedir. Resim 1’de sınıf etiketleri ve veri seti içerisindeki daęılımları gösterilmiřtir.




Figure 1 Obezite sınıflarının daęılımı (GUI)

Veri Ön İřleme

Model eęitiminden önce verilerin ön iřlemesi için çeřitli metodlar kullanılmıřtır. Bu ön iřleme sayesinde veri analize uygun hale getirilmiřtir. Makine öğrenmesi algoritmasının karmařık veriyi daha rahat anlaması saęlanmıřtır. Böylece geliřtirilen modelin tahmin performansı ve elde edilen sonuçların doęruluęu üst düzeye çıkarılmıřtır.

- **Label Encoding** (İkili deęiřkenler): Gender, family_history_with_overweight, FAVC, SMOKE, SCC → 0/1'e dönüřtürme
- **Ordinal Encoding** (Sıralı kategorik): CALC ve CAEC → {no:0, Sometimes:1, Frequently:2, Always:3}
- **One-Hot Encoding** (Nominal): MTRANS → 4 ikili sütuna dönüřtürme (`drop\_first=True`)
- **Ordinal Encoding** (Hedef): NObeyesdad → 0'dan 6'ya sıralı sayısal etiket

Veri ön işleme kısmında önemli bir soru ortaya çıkmıştır. Tahmin edilebileceği üzere bir obezite tahmin algoritmasının elinde boy ve kilo bilgilerinin bulunması sayesinde süreç tamamen modelin BMI formülünü öğrenmesine evrilmektedir. Literatür taraması yapıldığında bazı kaynakların boy ve kilo bilgisini özellik havuzundan çıkararak sadece yaşam tarzı verilerini kullanarak bir tahmin modeli oluşturduğu görülmüş; aynı zamanda bazı kaynaklar ise boy ve kilo bilgisini havuzda tutmuştur. Bu tercih doğrultusunda modelin accuracy (doğruluk) gibi değerlendirme sonuçları da büyük ölçüde değişmektedir. Bu projede ise her iki tercihin sonuçlarının da gösterilmesi amaçlanmıştır.

Yöntem: Karar Ağacı

Bu çalışmada sınıflandırma algoritması olarak CART (Classification and Regression Trees — Sınıflandırma ve Regresyon Ağaçları) kullanılmıştır. CART, veriyi özellik değerlerine göre yinelemeli ikili bölünmelerle alt gruplara ayırarak çalışan, kural tabanlı ve yorumlanabilir bir makine öğrenmesi yöntemidir.

Algoritma her bölünme adımında "bu noktada hangi özelliği kullanırsam veriyi en saf hâle getiririm?" sorusunu sorar. Bu saflık ölçütü olarak çalışmada entropi ve bilgi kazancı kullanılmıştır.

CART'ın bu çalışma için tercih edilme nedeni; hem görsel hem de kural tabanlı yorumlanabilirliği sayesinde hangi beslenme ve yaşam tarzı faktörlerinin obezite tahminine ne ölçüde katkı sağladığının açıkça ortaya konabilmesidir. Nitekim eğitim sonrasında elde edilen ağaç yapısı incelendiğinde, modelin sebze tüketim sıklığı, yaş ve teknoloji kullanım süresi gibi değişkenler üzerinden anlamlı bölünmeler yaptığı gözlemlenmiştir.

Bu çalışmada hiperparametre seçimi için GridSearchCV yöntemi uygulanmıştır. GridSearchCV, belirtilen tüm parametre kombinasyonlarını sistematik biçimde deneyerek çapraz doğrulama (cross-validation) skoru en yüksek olan kombinasyonu otomatik olarak seçer. Bu sayede araştırmacının tek tek deneme-yanılma yapması yerine en uygun parametre kümesi veri güdümlü olarak bulunmaktadır.

Çalışmada denenen parametre aralıkları aşağıdaki tabloda sunulmuştur:

Parametre	Denenen Değerler	Açıklama
criterion	entropy, gini	Bölünme kalitesini ölçen ölçüt
max_depth	None, 10, 12, 15, 18, 20, 25	Ağacın maksimum derinliği
min_samples_split	2, 3, 4, 5, 8, 12, 20	Bölünme için min. örnek sayısı
min_samples_leaf	1, 2, 3, 4, 5, 8	Yaprak için min. örnek sayısı
max_features	sqrt, log2, None	Bölünmede değerlendirilen özellik sayısı
class_weight	None, balanced	Sınıf dengesizliği ağırlıklandırması

GridSearchCV, bu parametrelerin tüm kombinasyonlarını StratifiedKFold (k=5) çapraz doğrulama ile değerlendirmiştir. Stratified yaklaşımın tercih edilmesinin nedeni, 7 sınıflı obezite probleminde her çapraz doğrulama katmanının (fold) eğitim verisindeki sınıf dağılımını yansıtmasının sağlanmasıdır; bu durum parametre seçiminin güvenilirliğini artırmaktadır.

Optimizasyon sonucunda her iki senaryo için bulunan en iyi parametreler ve sonuçları aşağıda verilmiştir:

Senaryo A (Boy + Kilo dahil): criterion=entropy, max_depth=None, min_samples_split=3, class_weight=balanced

```
Accuracy (Doğruluk): % 95.27
Sensitivity (Duyarlılık): % 95.27
Specificity (Özgüllük): % 95.02
F-measure: % 95.26
```

Figure 2 Senaryo A sonuçları




Figure 3 Senaryo A Karmaşıklık Matrisi




Figure 4 Senaryo A Özellik Önem Dereceleri

Senaryo B (Boy + Kilo hariç): criterion=entropy, max_depth=None, min_samples_split=2, class_weight=None

Accuracy (Doğruluk): % 81.32
Sensitivity (Duyarlılık): % 81.32
Specificity (Özgüllük): % 80.08
F-measure: % 81.48

Figure 5 Senaryo B sonuçları




Figure 6 Senaryo B Karmaşıklık Matrisi




Figure 7 Senaryo B Özellik Önem Dereceleri

Eğitim-test verisi ayrımı %80 eğitim / %20 test şeklinde yapılmıştır.

Senaryo A (Boy + Kilo dahil) için:

Şekil 4'te görüldüğü üzere, boy ve kilo bilgisinin modele dahil edildiği Senaryo A'da karar ağacı bölünmelerinin %81.19'u yalnızca iki değişken tarafından (Kilo (%61.67) ve Boy (%19.52)) açıklanmaktadır. Cinsiyet (%11.69) üçüncü sırada yer alırken diğer tüm özellikler toplamda %6'nın altında kalmaktadır. Bu sonuç, modelin obezite sınıflarını büyük ölçüde BMI formülüne benzer bir mantıkla dolaylı olarak ağırlık ve boy oranına dayanarak öğrendiğini göstermektedir. Yaşam tarzı değişkenleri (sebze tüketimi, fiziksel aktivite, su tüketimi vb.) bu senaryoda pratikte hiçbir belirleyici rol üstlenememektedir; çünkü ağaç, bu özelliklerle dallanmaya gerek kalmaksızın yüksek saflığa ulaşabilmektedir.

Senaryo B (Boy + Kilo hariç) için:

Boy ve kilo bilgisi dışlandığında özellik önem dağılımı köklü biçimde değişmektedir (Şekil 7). Bu senaryoda Sebze Tüketim Sıklığı (FCVC) %18.95 ile en belirleyici özellik konumuna yükselirken, Yaş (%17.80) ve Teknoloji Kullanım Süresi (TUE) (%13.59) onu izlemektedir. Günlük öğün sayısı, cinsiyet, fiziksel aktivite sıklığı ve su tüketimi de modele anlamlı katkı sağlayan değişkenler arasındadır. Bu dağılım literatürdeki bulgularla uyumluluk göstermektedir: düşük sebze tüketimi, uzun süreli ekran başında geçirilen zaman ve yetersiz fiziksel aktivite obezite riskini artıran yaşam tarzı faktörleri olarak pek çok çalışmada öne çıkmaktadır. Senaryo B'nin en dikkat çekici bulgusu, özellik öneminin çok sayıda değişken arasında dağılması ve böylece modelin obeziteyi daha bütüncül bir yaşam tarzı örüntüsü olarak kavrayabilmesidir.

Çalışmada 'Senaryo B' için elde edilen %81.32 doğruluk değeri, sabit bir %80/%20 eğitim/test bölünmesine dayanmaktadır. Ancak bu oran tek bir bölünme senaryosunu yansıtmakta olup farklı veri bölünmelerinde sonuçların belirgin biçimde değişebildiği gözlemlenmiştir.

Bu değişkenliği ölçmek amacıyla 0–299 arasında 300 farklı rastgele bölünme (random state) denenmiş ve her biri için model aynı hiperparametre optimizasyon süreci (GridSearchCV) uygulanarak değerlendirilmiştir. Elde edilen sonuçlar aşağıdaki tabloda özetlenmiştir:

Ölçüm	Değer
Ortalama Doğruluk	%76.43
Standart Sapma	±2.08
Minimum Doğruluk	%70.69
Maksimum Doğruluk	%82.03
Raporlanan Bölünme (seed=245)	% 81.32

GUI Kullanımı

Projenin tanıtımı ve gösteriminin kolaylığı için bir GUI tasarlanmış olup çeşitli ayarlar bu arayüz üzerinden yapılabilmekte ve sonuçlar bu arayüz üzerinden gösterilmektedir.

Obezite Tahmin Modeli Arayüzü

1. Veri Keşfi

Obezite Sınıflarının Dağılımını Görüntüle

Yaş ve Kilo Dağılımlarını Görüntüle

2. Özellik Seçimi (Feature Selection)

Aşağıdaki sütunları veri setinden kaldır:

☐ Boy (Height) sütununu kaldır ☐ Kilo (Weight) sütununu kaldır

Not: Bu seçenekler aktifken model eğitilip Feature Importance grafiğinde değişim gözlemlenebilir.

3. Veri Ayırma

Test Verisi Yüzdesi (Örn: 20):

4. Model Eğitimi ve Değerlendirme

Modeli Eğit

Accuracy (Doğruluk): -
Sensitivity (Duyarlılık): -
Specificity (Özgüllük): -
F-measure: -

5. Model Görselleştirme

Confusion Matrix Görüntülesini Goster

Feature Importance Tablosunu Goster

Karar Ağacını Goster (İlk 3 Katman)

Figure 8 GUI Tasarımı

Literatür Karşılaştırması

Geliştirdiğimiz modelin sonuçları literatürdeki benzer çalışmalarla kıyaslandığında oldukça rekabetçi bulunmuştur. Mehmet Kıvrak tarafından yapılan çalışmada, veri setinde boy ve kilo bilgileri de yer almasına rağmen, karmaşık bir derin öğrenme (Deep Learning) algoritması kullanılarak %82.0 oranında bir doğruluk elde edilmiştir. Bizim çalışmamızda ise boy ve kilo gibi doğrudan belirleyici olan bu özellikler modele dahil edilmeden, yalnızca yaşam tarzı verileriyle ve çok daha sade bir Karar Ağacı algoritmasıyla spesifik bir veri bölünmesinde %81.32'lik bir doğruluk oranına ulaşılmış olup, bu değer derin öğrenme modelinin performansına oldukça yakındır. Öte yandan, tıpkı bizim 'Senaryo B' modelimizde olduğu gibi boy ve kilo verilerinin veri setinden çıkarıldığı 2021 ISAIAM konferansındaki çalışmada Karar Ağacı algoritmasıyla %74.94 doğruluk sağlanabilmiştir. Tekil bir eğitim/test bölünmesinde elde ettiğimiz %81.32'lik sonuç literatürdeki bu değerden belirgin şekilde yüksek görünse de, bu farkın temel olarak veri bölünmesinden (train/test split) kaynaklanan metodolojik farklılıklara dayandığı değerlendirilmektedir. Nitekim modelimizin 300 farklı rastgele bölünme senaryosundaki ortalama doğruluğu %76.43 olarak hesaplanmış olup, bu değer ISAIAM çalışmasındaki sonuçla paralellik ve tutarlılık göstermektedir. Ortalama başarı oranımız literatürle benzer bir temelde otursa da, doğru veri ön işleme adımlarının uygulanması ve sistematik hiperparametre optimizasyonunun (GridSearchCV) modele entegre edilmesiyle %81.32 gibi yüksek doğruluk oranlarına ulaşılabileceğinin görülmesi, analiz süreçlerinde bu adımların ne kadar kritik bir öneme sahip olduğunu vurgulamaktadır.

Sonuç

Bu çalışmada, Karar Ağacı (CART) algoritması kullanılarak bireylerin beslenme alışkanlıkları ve yaşam tarzı verilerinden obezite seviyelerinin tahmin edilmesi amaçlanmıştır. Geliştirilen model, boy ve kilo verilerinin dahil edildiği ve edilmediği iki farklı senaryo üzerinden eğitilerek test edilmiştir. Boy ve kilo bilgisi olmadan yalnızca yaşam tarzı verileriyle %81.32 doğruluk elde edilmesi, bu özelliklerin obezite tahmini için klinik açıdan anlamlı belirleyiciler olduğunu göstermektedir. Gelecek çalışmalarda; veri setinin daha büyük ve sentetik olmayan gerçek verilerle genişletilmesi, Random Forest veya Gradient Boosting gibi farklı algoritmalarla topluluk modelleri kurulması ve elde edilen bu tahmin sistemlerinin doğrudan gerçek klinik uygulamalara entegre edilmesi önerilmektedir.

Bağlantılar

Proje kaynak kodları : <https://github.com/rosebud42/obesitydataset-decision-tree>

Proje anlatım videosu: <https://www.youtube.com/watch?v=0mrjudTrIIQ>

Kaynakça

Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). *Classification and Regression Trees*. Taylor & Francis.

Cui, T., Chen, Y., Wang, J., Deng, H., & Huang, Y. (2021). Estimation of obesity levels based on Decision trees. *2021 International Symposium on Artificial Intelligence and its Application on Media (ISAIAAM)*, 190-204. IEEE.

Kivrak, M. (2021). Deep learning-based prediction of obesity levels according to eating habits and physical condition. *The Journal of Cognitive Systems*, 6(1), 24-27.

Palechor, F. M., & De la Hoz Manotas, A. (2019). Dataset for estimation of obesity levels based on eating habits and physical condition in individuals from Colombia, Peru and Mexico. *Data in Brief*, 25, 104344.

Scikit-learn Developers. (n.d.). *sklearn.model_selection.GridSearchCV*. Scikit-learn Machine Learning in Python. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html

Scikit-learn Developers. (n.d.). *sklearn.tree.DecisionTreeClassifier*. Scikit-learn Machine Learning in Python. <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html>